

Nama : Matthew Sutiono
NIM : 2802393503

1. Batch Normalization bekerja dengan menormalisasi aktivasi berdasarkan mean dan variance dari setiap mini-batch. Karena isi mini-batch selalu berubah selama proses training, nilai mean dan variance yang dihitung juga sedikit berbeda. Perubahan kecil ini menimbulkan semacam noise pada aktivasi, sehingga model tidak terlalu bergantung pada pola tertentu dan menjadi lebih sulit untuk overfitting. Karena efek tersebut, BatchNorm bisa berperan sebagai mild regularization, seperti yang disebutkan pada Slide 8.

Namun, ini tidak berarti Dropout selalu tidak diperlukan. Jika model masih terlalu kompleks atau tetap mengalami overfitting, Dropout masih bisa membantu. Selain itu, jika batch size terlalu kecil, estimasi mean dan variance menjadi kurang stabil sehingga proses training juga bisa ikut tidak stabil.

Slide → 6 - 8

Sumber Eksternal → Ioffe & Szegedy (2015), Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. <https://arxiv.org/abs/1502.03167>

2. Menambah jumlah layer pada CNN tidak selalu membuatnya lebih baik. Pada jaringan yang sangat dalam, proses training justru bisa menjadi lebih sulit karena gradient dapat semakin kecil atau besar ketika melewati banyak layer. Kondisi ini dapat menyebabkan degradation problem, yaitu ketika jaringan yang lebih dalam memiliki training accuracy yang lebih buruk dibanding jaringan yang lebih dangkal. Hal ini juga disebutkan pada Slide 10.

Residual connection membantu mengatasi masalah tersebut dengan menambahkan jalur langsung dari input ke output melalui rumus $y = F(x) + x$. Dengan adanya skip connection, gradient tidak harus selalu melewati seluruh layer secara berurutan, tetapi memiliki jalur alternatif untuk mengalir ke layer sebelumnya. Karena itu, risiko vanishing gradient berkurang dan jaringan yang lebih dalam menjadi lebih mudah dilatih.

Slide → 10 - 12

Sumber Eksternal → He et al. (2016), Deep Residual Learning for Image Recognition. <https://arxiv.org/abs/1512.03385>

3. Pada Feature Extraction, seluruh pretrained layer dibekukan dan hanya classifier baru yang dilatih. Karena hanya sedikit parameter yang diperbarui, proses training biasanya lebih cepat, membutuhkan memori lebih sedikit, dan cocok digunakan ketika dataset yang tersedia terbatas. Risiko merusak fitur yang sebelumnya sudah dipelajari oleh model pretrained juga lebih kecil.

Sebaliknya, pada Fine-Tuning, sebagian layer pretrained dibuka kembali agar bobotnya dapat ikut menyesuaikan dengan dataset baru. Pendekatan ini membutuhkan komputasi dan data yang lebih banyak, tetapi bisa menghasilkan representasi yang lebih sesuai dengan target domain. Slide 16 juga menyarankan agar layer dibuka secara bertahap dan menggunakan learning rate yang lebih kecil.

Jadi, feature extraction lebih cocok untuk dataset kecil dan domain yang mirip ImageNet, sedangkan fine-tuning lebih berguna ketika domain target cukup berbeda dan model perlu beradaptasi lebih jauh.

Slide → 14 - 18

Sumber Eksternal → PyTorch, Transfer Learning for Computer Vision Tutorial.
https://docs.pytorch.org/tutorials/beginner/transfer_learning_tutorial.html

4. Data augmentation sebaiknya hanya diterapkan pada training set karena tujuannya adalah membuat variasi data tambahan agar model tidak hanya menghafal data training. Dengan transformasi seperti horizontal flip, rotation, crop, atau color jitter, model akan melihat versi gambar yang sedikit berbeda dan diharapkan dapat melakukan generalisasi lebih baik. Hal ini terutama berguna ketika dataset yang tersedia tidak terlalu besar.

Sebaliknya, validation dan test set sebaiknya tidak menggunakan random augmentation karena data tersebut digunakan untuk mengevaluasi performa model secara konsisten. Jika gambarnya terus berubah saat evaluasi, hasil accuracy dan loss juga bisa berubah karena transformasi tersebut.

Untuk klasifikasi ras hewan, contoh augmentation yang kurang cocok adalah perubahan warna atau hue yang terlalu ekstrem, karena warna dan pola bulu bisa menjadi ciri penting suatu ras. Transformasi sebaiknya tetap menjaga informasi yang berhubungan dengan label asli.

Slide → 20 - 22

Sumber Eksternal → Shorten & Khoshgoftaar (2019), A Survey on Image Data Augmentation for Deep Learning.
<https://link.springer.com/article/10.1186/s40537-019-0197-0>

5. Catastrophic forgetting dapat terjadi ketika model pre trained di-fine-tune terlalu agresif. Jika pretrained layer langsung diubah menggunakan learning rate yang besar, bobot yang sebelumnya sudah mempelajari fitur umum dari dataset besar seperti ImageNet dapat berubah terlalu jauh. Akibatnya, model bisa kehilangan sebagian representasi yang sebenarnya masih berguna. Slide 28 juga menyebutkan bahwa catastrophic forgetting dapat terjadi jika proses fine-tuning dilakukan terlalu cepat.

Salah satu cara mengatasinya adalah menggunakan differential learning rate, yaitu memberikan learning rate kecil pada pretrained layer dan learning rate lebih besar pada classifier baru. Cara lainnya adalah gradual unfreezing, yaitu membuka layer secara bertahap, bukan semuanya sekaligus. Pendekatan ini memberi kesempatan kepada model untuk beradaptasi secara perlahan tanpa mengubah pretrained features terlalu drastis. Strategi tersebut juga sesuai dengan pendekatan fine-tuning pada Slide 16.

Slide → 16, 28 - 29

Sumber Eksternal → Li & Hoiem (2016), Learning without Forgetting.
<https://arxiv.org/abs/1606.09282>