

C1. Tabel Konsolidasi dan Visualisasi Pembelajaran


Saya menggunakan dataset Oxford-IIIT Pet dengan 10 kelas (5 ras kucing dan 5 ras anjing), berjumlah 1.981 gambar. Data dibagi secara stratified menjadi 1.386 training (70%), 297 validation (15%), dan 298 test (15%). Seluruh eksperimen menggunakan input 224×224 , normalisasi ImageNet, seed 42, batch size 32, AdamW, CrossEntropyLoss, weight decay 0,01, serta early stopping berdasarkan validation loss dengan patience 4.

Tabel Hasil Eksperimen (B1 - B5) :

Kondisi	Trainable Parameters	Learning Rate	Best / Total Epoch	Waktu (s)	Val. Acc.	Test Macro F1
B1 (Scratch)	11.181.642	1e-3	7 / 11	164,44	47,14%	0,4997
B2 (Feature Extraction)	5.130	FC: 1e-3	20 / 24	327,85	96,97%	0,9699
B3 (Fine-Tuning)	8.398.858	Layer4: 1e-4; FC: 1e-3	4 / 8	108,86	98,32%	0,9664
B4 (No Aug)	8.398.858	Layer4: 1e-4; FC: 1e-3	4 / 8	73,06	97,98%	0,9696
B4 (Aug)	8.398.858	Layer4: 1e-4; FC: 1e-3	4 / 8	109,38	98,32%	0,9664
B5 (EfficientNet-B0)	1.142.202	Fitur: 1e-4; Classifier: 1e-3	6 / 10	138,90	98,99%	0,9798

Dari tabel tersebut, saya melihat bahwa penggunaan pretrained model memberikan peningkatan performa yang jauh lebih besar dibanding training from scratch. EfficientNet-B0 memperoleh hasil terbaik dengan validation accuracy 98,99%, test accuracy 97,99%, dan Macro F1 sebesar 0,9798. Namun, B2 tetap menarik karena menghasilkan performa yang cukup dekat hanya dengan melatih 5.130 parameter.

Visualisasi learning curves



Pada B1, validation loss berfluktuasi meskipun training loss terus turun, menunjukkan proses pembelajaran yang belum stabil. B2 jauh lebih stabil karena menggunakan pretrained features. Sementara itu, B3 mencapai validation loss terbaik pada epoch 4, lalu mulai menunjukkan indikasi overfitting ketika training loss terus menurun tetapi validation loss meningkat.

C2. Pembahasan Analisis Komparatif

From Scratch vs. Transfer Learning. B1 hanya memperoleh test accuracy 52,01%, sedangkan B2 mencapai 96,98%. Menurut saya, perbedaan ini terjadi karena B1 harus mempelajari seluruh fitur visual dari sekitar 1.386 gambar training. Residual connection membantu proses optimisasi jaringan dalam (Slide 10–12), tetapi tidak menggantikan kebutuhan data yang memadai. Sebaliknya, pretrained ImageNet pada B2 menyediakan representasi yang sudah berguna, sehingga transfer learning jauh lebih efektif untuk dataset kecil (Slide 16).


Feature Extraction vs. Fine-Tuning. B3 meningkatkan validation accuracy dari 96,97% menjadi 98,32%, tetapi test accuracy justru sedikit lebih rendah daripada B2 (96,64% vs. 96,98%). B3 juga melatih 8,40 juta parameter, jauh lebih banyak daripada B2 yang hanya melatih 5.130 parameter. Ini menunjukkan bahwa fine-tuning dapat membantu adaptasi fitur, tetapi peningkatannya tidak selalu bertahan pada test set. Total waktu B2 lebih lama (327,85 detik) dibanding B3 (108,86 detik) karena B2 menjalankan 24 epoch, sedangkan B3 hanya 8 epoch. Jadi, durasi tersebut tidak membuktikan bahwa fine-tuning selalu lebih hemat komputasi.

Pengaruh Augmentation. Pada B4, generalization gap turun dari 2,02 percentage points tanpa augmentation menjadi 0,46 dengan augmentation. Artinya, augmentation membantu mengurangi perbedaan performa training dan validation. Namun, test accuracy sedikit turun dari 96,98% menjadi 96,64%. Menurut saya, augmentation memberikan efek regularisasi, tetapi tidak otomatis meningkatkan performa akhir (Slide 20–22). Gap juga perlu diinterpretasikan hati-hati karena training accuracy pada kondisi augmentation diukur menggunakan gambar yang telah ditransformasi.

Perbandingan Arsitektur. EfficientNet-B0 menghasilkan Macro F1 tertinggi (0,9798) dengan total parameter sekitar 4,02 juta, lebih sedikit daripada ResNet-18 (11,18 juta). Namun, waktu training B5 sebesar 138,90 detik belum membuktikan bahwa inference-nya lebih cepat. Menurut saya, B5 memberikan trade-off performa dan ukuran model yang menarik, tetapi efisiensi deployment tetap perlu diuji secara terpisah (Slide 24 dan 28).

C3. Failure Analysis

Model terbaik (EfficientNet-B0) berhasil memprediksi 292 dari 298 gambar test dengan benar, sehingga terdapat enam kesalahan.



Tabel Analisis Misklasifikasi :

Ground Truth → Prediction	Confidence	Hipotesis Penyebab
British Shorthair → Bombay	92,98%	Bayangan membuat bulu terlihat gelap dan menyerupai Bombay.
Abyssinian → British Shorthair	84,25%	Sudut samping dan bulu yang tampak tebal menyamarkan ciri ras.
Abyssinian → Bengal	65,15%	Posisi telentang membuat bentuk wajah sulit dikenali.
Birman → Bombay	59,73%	Close-up wajah gelap membuat pola bulu terang kurang terlihat.
Bengal → Abyssinian	56,08%	Fokus pada wajah sehingga pola bulu badan tidak terlihat jelas.
Chihuahua → Bombay	51,64%	Subjek kecil dan berwarna hitam dengan latar rumput; siluet mungkin menyerupai kucing.

Dari hasil ini, saya melihat bahwa kesalahan terutama berkaitan dengan kemiripan visual, pencahayaan, pose, dan sudut pengambilan gambar. Kasus British Shorthair yang diprediksi sebagai Bombay dengan confidence 92,98% juga menunjukkan bahwa model dapat sangat yakin meskipun prediksinya salah. Karena itu, confidence tinggi tidak selalu menjamin prediksi benar.


C4. Rekomendasi Rekayasa dan Batasan Eksperimen

Rekomendasi. Jika target utama adalah performa tertinggi, saya memilih EfficientNet-B0 fine-tuning dengan augmentation karena memperoleh Macro F1 0,9798 dan test accuracy 97,99%. Namun, untuk kebutuhan training yang sederhana dan terbatas, ResNet-18 feature extraction tetap menarik karena hanya melatih 5.130 parameter dengan Macro F1 0,9699. Pada penggunaan nyata, saya menyarankan evaluasi tambahan untuk gambar dengan pose ekstrem, pencahayaan buruk, serta pemeriksaan manual pada prediksi yang meragukan.

Batasan. Eksperimen ini hanya menggunakan satu seed (42), satu pembagian data 70/15/15, dan 10 dari 37 kelas Oxford-IIIT Pet. Saya belum menguji variasi augmentation lain, dataset eksternal, atau inference latency. Selain itu, bagian jaringan yang dilatih pada ResNet-18 dan EfficientNet-B0 berbeda. Karena itu, hasil perbandingan ini lebih tepat digunakan sebagai evaluasi konfigurasi praktis pada klasifikasi data terbatas yang menyerupai ImageNet, bukan kesimpulan bahwa suatu arsitektur selalu lebih unggul.

C5. Eksplorasi Tambahan (Feature Map Comparison)

Saya membandingkan aktivasi layer4 ResNet-18 pretrained ImageNet dengan checkpoint B3 setelah fine-tuning, menggunakan tiga gambar test: satu Boxer yang diprediksi benar dan dua Abyssinian yang salah diprediksi sebagai Bengal. Feature map diperoleh dengan menggabungkan kekuatan aktivasi antar-channel dan menghitung selisihnya.



Hasil visualisasi memperlihatkan perubahan kekuatan dan distribusi aktivasi setelah fine-tuning, terutama pada area objek. Rata-rata perubahan absolut aktivasi layer 4 adalah 0,8002 pada Boxer serta 0,7851 dan 0,7505 pada kedua Abyssinian. Namun, dua gambar Abyssinian tetap salah diprediksi sebagai Bengal dengan confidence 94,94% dan 85,81%.

Menurut saya, hasil ini menunjukkan bahwa fine-tuning mengubah respons representasi fitur, tetapi perubahan tersebut tidak selalu memperbaiki setiap prediksi (Slide 29). Visualisasi ini merupakan agregasi aktivasi, bukan Grad-CAM yang menjelaskan satu kelas secara khusus, sehingga tidak dapat digunakan untuk memastikan bagian gambar mana yang menentukan keputusan model.

Kesimpulan

Eksperimen ini menunjukkan bahwa transfer learning jauh lebih efektif dibanding training from scratch pada data terbatas. Fine-tuning dan augmentation dapat membantu adaptasi serta regularisasi, tetapi tidak selalu meningkatkan test accuracy. EfficientNet-B0 memberikan performa terbaik, sedangkan feature extraction tetap kompetitif dari sisi jumlah parameter yang dilatih. Hasil C5 juga memperlihatkan perubahan representasi setelah fine-tuning, meskipun kesalahan pada ras yang mirip masih terjadi.

Referensi

- Materi Sesi 05, Advanced CNNs and Transfer Learning, Slide 10–12, 16, 20–22, 24, dan 28–29.
- He et al. (2016), Deep Residual Learning for Image Recognition. <https://arxiv.org/abs/1512.03385>
- Tan & Le (2019), EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. <https://arxiv.org/abs/1905.11946>
- PyTorch, Transfer Learning for Computer Vision Tutorial. https://docs.pytorch.org/tutorials/beginner/transfer_learning_tutorial.html

Pernyataan Penggunaan AI

Saya menggunakan ChatGPT (GPT-6) untuk membantu pembuatan dan pemeriksaan kode, klarifikasi konsep, serta peninjauan draf analisis. Notebook dijalankan di Google Colab dan hasilnya diperiksa melalui log CSV/JSON serta visualisasi. Interpretasi akhir ditinjau kembali berdasarkan hasil eksperimen dan pemahaman saya sendiri.